



## RAPPORT FINAL DE PROJET DE COMPILATION

---

# Développement d'un compilateur pour le langage CanAda

---

Alexis MARCEL  
Lucas LAURENT  
Noé STEINER

*Responsable du module :*  
M. Olivier FESTOR  
Mme. Suzanne COLLIN

15 Janvier 2024

# Table des matières

<b>1</b>	<b>Contexte du projet</b>	<b>2</b>
<b>2</b>	<b>Introduction</b>	<b>2</b>
<b>3</b>	<b>Grammaire</b>	<b>2</b>
3.1	Présentation . . . . .	2
3.2	Étapes de Transformation de la Grammaire . . . . .	3
3.3	Grammaire Originale en BNF . . . . .	3
3.3.1	Élimination de la Récursivité à Gauche . . . . .	5
3.3.2	Factorisation à Gauche . . . . .	5
3.3.3	Gestion des Priorités de Calculs . . . . .	6
3.4	Grammaire Transformée en LL(1) . . . . .	6
3.5	Table LL(1) . . . . .	9
<b>4</b>	<b>Analyse Lexicale pour canAda</b>	<b>9</b>
4.1	Structure et Fonctionnement du Lexer . . . . .	10
4.2	Gestion des Tokens . . . . .	10
4.3	Optimisation et Fiabilité . . . . .	11
<b>5</b>	<b>Analyse Syntaxique</b>	<b>11</b>
5.1	Structure et Fonctionnement . . . . .	11
5.2	Interaction avec l'Analyseur Lexical . . . . .	12
5.3	Gestion des Erreurs Syntaxiques . . . . .	12
<b>6</b>	<b>Construction de l'Arbre Abstrait Syntaxique pour canAda</b>	<b>12</b>
6.1	Structure et Fonctionnement de l'AST . . . . .	12
6.2	Représentation des Structures Syntaxiques . . . . .	14
6.3	Rôle dans le Processus de Compilation . . . . .	14
<b>7</b>	<b>Tests et Validation</b>	<b>14</b>
7.1	Pour un code source valide . . . . .	14
7.2	Pour un code source invalide . . . . .	17
<b>8</b>	<b>Gestion de projet</b>	<b>19</b>
8.1	Équipe de projet . . . . .	19
8.2	Organisation au sein de l'équipe projet . . . . .	19
8.3	Matrice RACI . . . . .	19
8.4	Répartition du Temps de Travail sur le Projet . . . . .	20
<b>9</b>	<b>Conclusion</b>	<b>20</b>

# 1 Contexte du projet

Ce rapport présente le projet réalisé dans le cadre du module PCL1 de la première année du cycle ingénieur à TELECOM Nancy. L'objectif principal est de développer, en groupe, un compilateur pour le langage *canAda*, une version simplifiée d'Ada. Ce projet est une opportunité d'approfondir nos compétences en analyse lexicale et syntaxique ainsi que la construction d'un arbre abstrait.

## 2 Introduction

Dans le cadre de nos études, la compréhension et le développement de compilateurs se révèlent cruciaux car ils permettent de mieux comprendre les principes fondamentaux de l'informatique, comme la structure des langages de programmation, l'analyse syntaxique ou encore les arbres abstraits. Cette connaissance est essentielle pour optimiser les performances des programmes, assurer leur sécurité, et développer des logiciels fiables et efficaces. Le projet *canAda* s'inspire d'Ada, un langage connu pour sa fiabilité et sa sécurité. Ce travail nous plonge dans la complexité de la compilation, nous préparant à des applications concrètes dans divers secteurs tels que les systèmes embarqués, la défense, ou l'aéronautique. En développant un compilateur, nous affrontons non seulement les défis techniques relatifs à la conception d'un tel compilateur mais aussi nous nous créons une base de connaissances fondamentale pour nous, futurs ingénieurs. Nous avons pris comme décision de faire ce projet en Java car nous avons envie d'approfondir notre connaissance de ce langage et de ses outils.

## 3 Grammaire

### 3.1 Présentation

Le sujet nous a fourni une grammaire associée au langage *canAda*. Cette grammaire est une version simplifiée de la grammaire du langage Ada et était sous une forme abstraite avec notamment des regex.

```

<fichier> ::= with Ada.Text_IO; use Ada.Text_IO;
           procedure <ident> is <decl>*
           begin <instr>+ end <ident>? ; EOF
<decl>    ::= type <ident> ;
           | type <ident> is access <ident> ;
           | type <ident> is record <champs>+ end record ;
           | <ident>+ : <type> (:= <expr>)? ;
           | procedure <ident> <params>? is <decl>*
           | begin <instr>+ end <ident>? ;
           | function <ident> <params>? return <type> is <decl>*
           | begin <instr>+ end <ident>? ;
<champs>  ::= <ident>+ : <type> ;
<type>    ::= <ident>
           | access <ident>
<params>  ::= ( <param>+ )
<param>   ::= <ident>+ : <mode>? <type>
<mode>    ::= in | in out
<expr>    ::= <entier> | <caractère> | true | false | null
           | ( <expr> )
           | <accès>
           | <expr> <opérateur> <expr>
           | not <expr> | - <expr>
           | new <ident>
           | <ident> ( <expr>+ )
           | character ' val ( <expr> )
<instr>   ::= <accès> := <expr> ;
           | <ident> ;
           | <ident> ( <expr>+ ) ;
           | return <expr>? ;
           | begin <instr>+ end ;
           | if <expr> then <instr>+ (elsif <expr> then <instr>+)*
           | (else <instr>+)? end if ;
           | for <ident> in reverse? <expr> .. <expr>
           | loop <instr>+ end loop ;
           | while <expr> loop <instr>+ end loop ;
<opérateur> ::= = | /= | < | <= | > | >=
           | + | - | * | / | rem
           | and | and then | or | or else
<accès>    ::= <ident> | <expr> . <ident>

```

FIGURE 1 – Grammaire initiale du Sujet

### 3.2 Étapes de transformation de la Grammaire

Grammaire originale en BNF

La grammaire initiale du langage *canAda*, avant sa transformation en grammaire LL(1), se présente comme suit en BNF sans les regex :

1	<code>fichier -&gt; withAda.Text_IO ; useAda.Text_IO ; procedure ident is &lt;decls&gt;</code>
2	<code>begin &lt;instrs&gt; end &lt;hasident&gt; ; EOF</code>
3	<code>decl -&gt; type ident ;</code>

```

4      | type ident is access ident ;
5      | type ident is record <champs> end record ;
6      | <identsep> : <type> <typexpr> ;
7      | procedure ident <hasparams> is <decls> begin <instrs> end <
      |   hasident> ;
8      | function ident <hasparams> return <type> is <decls> begin <
      |   instrs> end <hasident> ;
9
10     decls -> <decl> <decls>
11           | ε
12
13     hasident -> ident
14              | ε
15
16     identsep -> ident , <identsep>
17              | ident
18
19     champ -> <identsep> : <type> ;
20
21     champs -> <champ> <champs>
22             | <champ>
23
24     type -> ident
25           | access ident
26
27     params -> ( <paramsep> )
28
29     hasparams -> <params>
30                | ε
31
32     paramsep -> <param> ; <paramsep>
33              | <param>
34
35     typexpr -> := <expr>
36             | ε
37
38     param -> <identsep> : <mode> <type>
39
40     mode -> in
41           | in out
42           | ε
43
44     expr -> entier
45           | caractre
46           | true
47           | false
48           | null
49           | ( <expr> )
50           | <acces>
51           | <expr> <op rateur> <expr>
52           | not <expr>
53           | - <expr>
54           | new ident
55           | ident ( <exprsep> )
56           | character ' val ( <expr> )
57
58     exprsep -> <expr> , <exprsep>
59             | <expr>

```

```

60
61     hasexpr -> <expr>
62             | ε
63
64     instr -> <acces> := <expr> ;
65             | ident ;
66             | ident ( <exprsep> ) ;
67             | return <hasexpr> ;
68             | begin <instrs> end ;
69             | if <expr> then <instrs> <elsif> <else> end if ;
70             | for ident in <hasreverse> <expr> .. <expr> loop <instrs>
              end loop ;
71             | while <expr> loop <instrs> end loop ;
72
73     elsif -> elsif <expr> then <instrs> <elsif>
74             | ε
75
76     else -> else <instrs>
77            | ε
78
79     hasreverse -> reverse
80                 | ε
81
82     instrs -> <instr> <instrs>
83              | <instr>
84
85     op rateur -> = | /= | < | <= | > | >= | + | - | * | / | rem |
              and | and then | or | or else
86
87     acces -> ident
88            | <expr> . ident

```

### 3.2.1 Élimination de la Récursivité à Gauche

La grammaire initiale comportait plusieurs instances de récursivité à gauche. Par exemple, la règle :

```

1     expr -> <acc s>
2     acces -> ident | <expr> . ident

```

a été transformée en :

```

1     expr -> ident <primary2>
2     primary2 -> ( <exprsep> ) <acces> | <acces>
3     acces -> . ident <acces> | ε

```

Cette modification élimine la (double ici) récursivité à gauche, rendant la grammaire adaptée pour une analyse LL(1). Une autre récursivité à gauche a été supprimé mais elle a été faite aussi à travers la priorisation des règles.

### 3.2.2 Factorisation à Gauche

La factorisation à gauche a été nécessaire pour certaines règles. Par exemple :

```

1     exprsep -> <expr> , <exprsep>
2     exprsep -> <expr>

```

a été réécrite en :

```

1     exprsep -> <expr> <exprsep'>
2     exprsep' -> , <expr> <exprsep'> | ε

```

Ceci assure que la règle peut être analysée de manière déterministe en LL(1).

### 3.2.3 Gestion des Priorités de Calculs

Pour gérer correctement les priorités des opérations, la grammaire a été ajustée. Par exemple, les opérations de multiplication et division ont été séparées des opérations d'addition et de soustraction pour respecter leur priorité :

1	<code>expr -&gt; &lt;expr&gt; &lt;opérateur&gt; &lt;expr&gt;</code>
a été réécrite en :	
1	<code>expr -&gt; &lt;or_expr&gt;</code>
2	<code>or_expr -&gt; &lt;and_expr&gt; &lt;or_expr'&gt;</code>
3	<code>or_expr' -&gt; or &lt;or_expr'2&gt;   ε</code>
4	<code>or_expr'2 -&gt; &lt;and_expr&gt; &lt;or_expr'&gt;</code>
5	<code>or_expr'2 -&gt; else &lt;and_expr&gt; &lt;or_expr'&gt;</code>
6	<code>and_expr -&gt; &lt;not_expr&gt; &lt;and_expr'&gt;</code>
[...]	
1	<code>unary_expr -&gt; - &lt;unary_expr&gt;</code>
2	<code>unary_expr -&gt; &lt;primary&gt;</code>
3	<code>primary -&gt; entier</code>
4	<code>primary -&gt; caractre</code>
5	<code>primary -&gt; true</code>
6	<code>primary -&gt; false</code>
7	<code>primary -&gt; null</code>
8	<code>primary -&gt; ( &lt;expr&gt; )</code>
9	<code>primary -&gt; ident &lt;primary2&gt;</code>
10	<code>primary -&gt; new ident</code>
11	<code>primary -&gt; character ' val ( &lt;expr&gt; )</code>

Cela permet de respecter la hiérarchie des opérations dans les expressions arithmétiques.

Les ensembles de sélection distincts ont été calculés pour assurer une sélection univoque lors de l'analyse.

Ces étapes illustrent comment la grammaire initiale a été transformée en une grammaire LL(1), adaptée pour une analyse syntaxique efficace et précise du langage *canAda*

### 3.3 Grammaire Transformée en LL(1)

La grammaire transformée en LL(1) se présente comme suit :

1	<code>fichier -&gt; withAda.Text_IO ; useAda.Text_IO ; procedure ident is decls</code>
	<code>begin instrs end hasident ; EOF</code>
2	<code>decl -&gt; type ident hasischoose ;</code>
3	<code>decl -&gt; identsep : type_n typexpr ;</code>
4	<code>decl -&gt; procedure ident hasparams is decls begin instrs end hasident</code>
	<code>;</code>
5	<code>decl -&gt; function ident hasparams return type_n is decls begin instrs</code>
	<code>end hasident ;</code>
6	
7	<code>hasischoose -&gt; is accorrec   ε</code>
8	
9	<code>accorrec -&gt; access ident</code>
10	<code>accorrec -&gt; record champs end record</code>
11	
12	<code>decls -&gt; decl decls</code>
13	<code>decls -&gt; ε</code>
14	
15	<code>hasident -&gt; ident</code>
16	<code>hasident -&gt; ε</code>
17	
18	<code>identsep -&gt; ident identsep2</code>

```

19      identsep2 -> , identsep
20      identsep2 ->  $\epsilon$ 
21
22
23      champ -> identsep : type_n ;
24
25      champs -> champ champs2
26
27      champs2 -> champs |  $\epsilon$ 
28
29      type_n -> ident
30      type_n -> access ident
31
32      params -> ( paramsep )
33
34      hasparams -> params
35      hasparams ->  $\epsilon$ 
36
37      paramsep -> param paramsep2
38
39      paramsep2 -> ; paramsep
40      paramsep2 ->  $\epsilon$ 
41
42      typexpr -> := expr
43      typexpr ->  $\epsilon$ 
44
45      param -> identsep : mode type_n
46
47      mode -> in modeout
48      mode ->  $\epsilon$ 
49
50      modeout -> out
51      modeout ->  $\epsilon$ 
52
53      expr -> or_expr
54
55      or_expr -> and_expr or_expr'
56
57      or_expr' -> or or_expr'2
58      or_expr' ->  $\epsilon$ 
59
60      or_expr'2 -> and_expr or_expr'
61      or_expr'2 -> else and_expr or_expr'
62
63      and_expr -> not_expr and_expr'
64
65      and_expr' -> and and_expr'2
66      and_expr' ->  $\epsilon$ 
67
68      and_expr'2 -> not_expr and_expr'
69      and_expr'2 -> then not_expr and_expr'
70
71      not_expr -> equality_expr not_expr'
72
73      not_expr' -> not equality_expr not_expr'
74      not_expr' ->  $\epsilon$ 
75
76      equality_expr -> relational_expr equality_expr'

```



```

77 equality_expr' -> = relational_expr equality_expr'
78 equality_expr' -> /= relational_expr equality_expr'
79 equality_expr' -> ε
80
81 relational_expr -> additive_expr relational_expr'
82
83 relational_expr' -> < additive_expr relational_expr'
84 relational_expr' -> <= additive_expr relational_expr'
85 relational_expr' -> > additive_expr relational_expr'
86 relational_expr' -> >= additive_expr relational_expr'
87 relational_expr' -> ε
88
89 additive_expr -> multiplicative_expr additive_expr'
90
91 additive_expr' -> + multiplicative_expr additive_expr'
92 additive_expr' -> - multiplicative_expr additive_expr'
93 additive_expr' -> ε
94
95 multiplicative_expr -> unary_expr multiplicative_expr'
96
97 multiplicative_expr' -> * unary_expr multiplicative_expr'
98 multiplicative_expr' -> / unary_expr multiplicative_expr'
99 multiplicative_expr' -> rem unary_expr multiplicative_expr'
100 multiplicative_expr' -> ε
101
102 unary_expr -> - unary_expr
103 unary_expr -> primary
104
105 primary -> entier
106 primary -> caractre
107 primary -> true
108 primary -> false
109 primary -> null
110 primary -> ( expr )
111 primary -> ident primary2
112 primary -> new ident
113 primary -> character ' val ( expr )
114
115 primary2 -> ( exprsep ) acces
116 primary2 -> acces
117
118 exprsep -> expr exprsep2
119
120 exprsep2 -> , exprsep
121 exprsep2 -> ε
122
123 hasexpr -> expr
124 hasexpr -> ε
125
126 instr -> ident instr2
127 instr -> return hasexpr ;
128 instr -> begin instrs end ;
129 instr -> if expr then instrs elifn elsen end if ;
130 instr -> for ident in hasreverse expr .. expr loop instrs end loop ;
131 instr -> while expr loop instrs end loop ;
132
133 instr2 -> instr3 := expr ;
134

```

```

135      instr2 -> ( exprsep ) instr3 hasassign ;
136      instr2 -> ;
137
138      instr3 -> . ident instr3
139      instr3 -> ε
140
141      hasassign -> := expr
142      hasassign -> ε
143
144      elifn -> elif expr then instrs elifn
145      elifn -> ε
146
147      elsen -> else instrs
148      elsen -> ε
149
150      hasreverse -> reverse
151      hasreverse -> ε
152
153      instrs -> instr instrs2
154
155      instrs2 -> instr instrs2
156      instrs2 -> ε
157
158      acces -> . ident acces
159      acces -> ε

```

### 3.4 Table LL(1)

A l'aide de la grammaire transformée en LL(1), nous avons pu construire la table LL(1) suivante pour produire notre Parser. Ci-dessous, nous présentons une partie de la table LL(1) pour des raisons de lisibilité.

	\$	withAda.Text_IO.useAda.Text_IO;	procedure	ident	is	begin	end	:
S		S := fichier \$						
fichier		fichier := withAda.Text_IO.useAda.Text_IO; procedure ident is decls begin instrs end hasident ; EOF						
decl			decl := procedure ident hasparams is decls begin instrs end hasident ;	decl := identsep type_n typeexpr ;				
hasichoose					hasichoose := is accorec;			hasichoose := ε
accorec								
decls			decls := decl decls	decls := decl decls		decls := ε		
hasident				hasident := ident				hasident := ε
identsep				identsep := ident identsep2				
identsep2								
champ				champ := identsep type_n				
champs				champs := champ champs2				
champs2				champs2 := champs			champs2 := ε	
type_n				type_n := ident				
params								
hasparams					hasparams := ε			
paramsep				paramsep := param paramsep2				
paramsep2								paramsep2 := ; paramsep
typeexpr								typeexpr := ε
param				param := identsep mode type_n				
mode				mode := ε				
modeout				modeout := ε				
expr				expr := or_expr				
or_expr				or_expr := and_expr or_expr				
or_expr2								or_expr2 := ε
or_expr2				or_expr2 := and_expr or_expr				
and_expr				and_expr := not_expr and_expr				

FIGURE 2 – Table partielle LL(1)

## 4 Analyse Lexicale pour canAda

L'analyse lexicale, une étape cruciale dans le processus de compilation, est gérée par notre classe *Lexer*. Cette classe est responsable de la conversion du code source en une série de tokens, facilitant ainsi l'analyse syntaxique ultérieure. Elle contient un *PeekingReader* codé par nos soins, qui permet de lire dans le flux de caractères pour identifier correctement les tokens complexes tout en conservant ce qui a

été lu et en lisant caractère par caractère. Elle contient également un *ErrorService* qui permet de gérer les erreurs lexicales mais aussi une map de mots clés qui permet de gérer les mots clés du langage, les opérateurs et les symboles.

## 4.1 Structure et Fonctionnement du Lexer

La classe *Lexer* lit le code source et identifie les différents tokens en se basant sur un ensemble de règles prédéfinies, il est codé à l'aide du pattern *Singleton* pour éviter d'avoir plusieurs instances de la classe. Chaque token est une instance de la classe *Token*, qui contient des informations telles que le type de token et la valeur lexicale associée contenu dans l'enum *Tag*.

## 4.2 Gestion des Tokens

Des classes spécifiques, comme *Tag* et *PeekingReader*, sont utilisées pour catégoriser les tokens et gérer efficacement la lecture en avance du code source. La classe *Tag* définit les différents types de tokens, c'est une enum, tandis que *PeekingReader* permet de lire en avance dans le flux de caractères pour identifier correctement les tokens complexes en se passant donc d'un automate à états finis. Cela repose sur deux fonctions complexes qui permettent de lire le flux de caractères et de déterminer si le caractère courant est la fin d'un token.

```
1      /**
2       * Check if the current character is the end of a token
3       *
4       * @return true if the current character is the end of a token,
5       *         false otherwise
6       */
7      private boolean isEndOfToken() {
8          char current = (char) currentChar;
9          int nextInt = this.reader.peek(1);
10         char next = (char) nextInt;
11
12         boolean isCurrentLetterOrDigit = Character.isLetterOrDigit(
13             current) || current == '_';
14         boolean isNextLetterOrDigit = Character.isLetterOrDigit(next
15             ) || next == '_';
16         boolean isNextWhitespace = Character.isWhitespace(next);
17
18         // If the current character is a whitespace or the end of
19         // the file, the current character is the end of the token
20         if (nextInt == -1 || isNextWhitespace) {
21             return true;
22         }
23         // If the current character is an identifier or an integer,
24         // the next character must not be a letter or a digit
25         if (isCurrentLetterOrDigit) {
26             return !isNextLetterOrDigit;
27         }
28
29         Token token = this.matchToken(lexeme.toString());
30
31         // If the current character is a token and the next
32         // character is not a token, the current character is the
33         // end of the token
34         if (token.tag() != Tag.UNKNOWN) {
35             Token nextToken = this.matchToken(lexeme.toString() +
36                 next);
37             return nextToken.tag() == Tag.UNKNOWN;
38         }
39     }
```

```

32         return false;
33     }

1     public Token nextToken() {
2
3         while ((this.currentChar = this.reader.read()) != -1) {
4
5             if (this.isComment()) {
6                 this.skipComment();
7             } else if (Character.isWhitespace((char) currentChar)) {
8                 this.skipWhitespace();
9             } else if (isCharacterLiteral()) {
10                return this.readCharacterLiteral();
11            } else {
12                lexeme.append((char) currentChar);
13                if (this.isEndOfToken()) {
14                    Token token = this.matchToken(lexeme.toString());
15                    ;
16                    lexeme.setLength(0); // clear the StringBuilder
17                    if (token.tag() == Tag.UNKNOWN) {
18                        this.errorService.registerLexicalError(new
19                            UnknownTokenException(token));
20                    }
21                    return token;
22                }
23            }
24
25            this.reader.close();
26            return new Token(Tag.EOF, this.reader.getCurrentLine(),
                lexeme.toString());
27        }
28    }

```

### 4.3 Optimisation et Fiabilité

Le *Lexer* est conçu pour être à la fois rapide et fiable, capable d'identifier précisément les tokens même dans des cas de syntaxe complexe grâce aux fonctions présentées ci-dessus. Cette précision est essentielle pour garantir une analyse syntaxique sans erreur dans les étapes suivantes du processus de compilation.

## 5 Analyse Syntaxique

### 5.1 Structure et Fonctionnement

La classe *Parser* a été conçue pour analyser les programmes écrits dans le langage *canAda*, il est codé, lui aussi, à l'aide du pattern *Singleton* pour éviter d'avoir plusieurs instances de la classe. Il contient le token courant et l'analyseur lexical, qui sont utilisés pour analyser le programme source. Chaque méthode de cette classe correspond à un non-terminal de la grammaire LL(1) et est responsable de l'analyse d'une structure syntaxique spécifique du langage. Par exemple, une méthode *expr()* est utilisée pour analyser les expressions, correspondant au non-terminal *expr* de la grammaire. Ces méthodes sont appelées récursivement pour construire l'arbre syntaxique du programme source.

```

1     @PrintMethodName
2     private void expr() {
3         switch (this.currentToken.tag()) {
4             case IDENT, OPEN_PAREN, DOT, ENTIER, CARACTERE, TRUE,
5                 FALSE, NULL, NEW, CHARACTER -> {
6                 or_expr();
7             }
8         }
9     }

```

```

7         }
8     }

```

## 5.2 Interaction avec l'Analyseur Lexical

Le *Parser* interagit étroitement avec l'analyseur lexical, recevant un flux de tokens qui sont analysés selon les règles de la grammaire. Cette interaction est cruciale pour la décomposition correcte du programme source en ses composants syntaxiques. On lit les tokens un par un et on les compare avec les règles de la grammaire. Si le token correspond à la règle, on passe au token suivant. Si le token ne correspond pas à la règle, on génère une erreur syntaxique.

```

1      @PrintMethodName
2      private void analyseTerminal(Tag tag) {
3          System.out.println("\t\t t\t\t" + this.currentToken);
4          if (!(this.currentToken.tag() == tag)) {
5              Token expectedToken = new Token(tag, this.currentToken.
6                  line(), TagHelper.getTagString(tag));
7              if (expectedToken.tag() == Tag.SEMICOLON) {
8                  this.errorService.registerSyntaxWarning(new
9                      MissingSemicolonException(this.currentToken));
10             } else {
11                 this.errorService.registerSyntaxError(new
12                     UnexpectedTokenException(expectedToken, this.
13                         currentToken));
14             }
15             // Contient le prochain token ou <EOF, currentLine, ">" si
16             // fin de fichier
17             if (this.currentToken.tag() == Tag.EOF) {
18                 return;
19             }
20             this.currentToken = lexer.nextToken();
21         }
22     }

```

## 5.3 Gestion des Erreurs Syntaxiques

Un aspect essentiel du *Parser* est sa capacité à gérer les erreurs syntaxiques comme nous le voyons dans le code ci-dessus. Lorsque le programme source ne respecte pas les règles de la grammaire, des messages d'erreur descriptifs sont générés, indiquant la ligne et le token attendu par rapport au token reçu, facilitant la localisation et la correction des erreurs par les développeurs. On a notamment appliqué le *Panic Mode* pour gérer les erreurs syntaxiques. Le *Parser* continue à analyser le programme source jusqu'à la fin tout en indiquant les erreurs rencontrées.

# 6 Construction de l'Arbre Abstrait Syntaxique pour canAda

La construction de l'arbre abstrait syntaxique (AST) est une étape essentielle du processus de compilation du langage *canAda*. L'AST représente la structure syntaxique du programme source d'une manière qui est à la fois concise et facile à manipuler pour les étapes suivantes de la compilation.

## 6.1 Structure et Fonctionnement de l'AST

Notre système d'AST est construit autour de la classe *ASTNode*, qui sert de classe de base pour les différents types de nœuds de l'arbre. Chaque nœud spécifique, comme *OperatorNode*, *ParameterNode*, ou *ProgramNode*, hérite de *ASTNode* et représente une construction syntaxique spécifique du langage.

Par exemple, *OperatorNode* représente une opération arithmétique ou logique, tandis que *ProgramNode* représente la structure globale du programme *canAda*.

```

1      public class ProgramNode extends ASTNode {
2          private ProcedureDeclarationNode rootProcedure;

```

```

3
4         public void setRootProcedure(ProcedureDeclarationNode
5             rootProcedure) {
6             this.rootProcedure = rootProcedure;
7             rootProcedure.setParent(this);
8         }
9     }

```

```

1     public class OperatorNode extends ASTNode {
2         private String operator;
3
4         public OperatorNode(String operator) {
5             this.operator = operator;
6         }
7
8     }

```

Et ainsi de suite pour chaque nœud de l'arbre. On utilise alors notre fonction *Override toString()* pour afficher l'arbre abstrait syntaxique de manière récursive qui est dans notre classe abstraite qui étend de nos différents nœuds. Ainsi on a juste à appeler la fonction *toString()* sur le nœud racine de l'arbre pour afficher l'arbre abstrait syntaxique qui récupère les différents nœuds de l'arbre et les affiche de manière récursive en récupérant les différents attributs de chaque nœud.

```

1     public String toString() {
2         Field[] fields = this.getClass().getDeclaredFields();
3         String className = this.getClass().getSimpleName();
4         StringBuilder res = new StringBuilder(colorize(className,
5             Attribute.YELLOW_TEXT()) + " : { \n");
6         if (isJson) {
7             res = new StringBuilder("{ \n");
8         }
9         int lastIndex = fields.length - 1;
10
11         for (int i = 0; i < fields.length; i++) {
12             Field field = fields[i];
13             field.setAccessible(true);
14             try {
15                 Object attributeValue = field.get(this);
16                 if (attributeValue instanceof String) {
17                     attributeValue = colorize("\n" + attributeValue
18                         + "\n", Attribute.GREEN_TEXT());
19                 }
20                 if (attributeValue == null) {
21                     attributeValue = colorize("null", Attribute.
22                         BRIGHT_MAGENTA_TEXT());
23                 }
24                 res.append("\t").append("\n").append(colorize(field.
25                     getName(), Attribute.RED_TEXT())).append("\n").
26                     append(" : ").append(attributeValue);
27                 if (i < lastIndex || !isJson) {
28                     res.append(",");
29                 }
30                 res.append(" \n");
31             } catch (IllegalAccessException e) {
32                 System.err.println("Erreur lors de l'accès au champ
33                     " + field.getName());
34             }
35         }
36     }

```

```
30         }
31         res.append("}");
32         return format(res.toString());
33     }
```

## 6.2 Représentation des Structures Syntaxiques

Les nœuds de l'AST capturent les éléments essentiels des structures syntaxiques du programme, comme les opérations, les paramètres, et la structure globale du programme. Par exemple, *OperatorNode* représente une opération arithmétique ou logique, tandis que *ProgramNode* représente la structure globale du programme *canAda*.

## 6.3 Rôle dans le Processus de Compilation

L'AST joue un rôle central dans le processus de compilation. Après l'analyse syntaxique, le programme source est transformé en un AST, qui est ensuite utilisé pour les étapes de vérification sémantique, d'optimisation, et de génération de code. Cette représentation permet une manipulation plus aisée et plus efficace du programme source.

# 7 Tests et Validation

## 7.1 Pour un code source valide

Voici un code source valide en *canAda* qui permet de tester notre compilateur :

```
1      with Ada.Text_IO; useAda.Text_IO;
2      procedure Main is
3          A : Integer := 5;
4          B : Integer := 10;
5          Sum : Integer;
6      begin
7          Sum := A + B;
8      end Main;
```

On obtient alors après l'analyse lexicale et syntaxique la sortie suivante, on l'a découpé en 3 parties pour plus de lisibilité et laisser sur fond noir pour faciliter la lisibilité des couleurs :

```

-> Parser rule fichier called
-> Parser rule analyseTerminal called
  -> <WITH, 1, with>
-> Parser rule analyseTerminal called
  -> <IDENT, 1, Ada>
-> Parser rule analyseTerminal called
  -> <DOT, 1, .>
-> Parser rule analyseTerminal called
  -> <IDENT, 1, Text_IO>
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 1, ;>
-> Parser rule analyseTerminal called
  -> <IDENT, 1, useAda>
-> Parser rule analyseTerminal called
  -> <DOT, 1, .>
-> Parser rule analyseTerminal called
  -> <IDENT, 1, Text_IO>
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 1, ;>
-> Parser rule analyseTerminal called
  -> <PROCEDURE, 2, procedure>
-> Parser rule analyseTerminal called
  -> <IDENT, 2, Main>
-> Parser rule analyseTerminal called
  -> <IS, 2, is>
-> Parser rule multipleDeclarations called
-> Parser rule declaration called
-> Parser rule identsep called
-> Parser rule analyseTerminal called
  -> <IDENT, 3, A>
-> Parser rule identsep2 called
-> Parser rule analyseTerminal called
  -> <COLON, 3, :>
-> Parser rule type_n called
-> Parser rule analyseTerminal called
  -> <IDENT, 3, Integer>
-> Parser rule typexpr called
-> Parser rule analyseTerminal called
  -> <ASSIGN, 3, :=>
-> Parser rule expr called
-> Parser rule or_expr called
-> Parser rule and_expr called
-> Parser rule not_expr called
-> Parser rule equality_expr called
-> Parser rule relational_expr called
-> Parser rule additive_expr called
-> Parser rule multiplicative_expr called
-> Parser rule unary_expr called
-> Parser rule primary called
-> Parser rule analyseTerminal called
  -> <ENTIER, 3, 5>
-> Parser rule multiplicative_expr2 called
-> Parser rule additive_expr2 called
-> Parser rule relational_expr2 called

```

```

-> Parser rule equality_expr2 called
-> Parser rule not_expr2 called
-> Parser rule and_expr2 called
-> Parser rule or_expr2 called
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 3, ;>
-> Parser rule multipleDeclarations called
-> Parser rule declaration called
-> Parser rule identsep called
-> Parser rule analyseTerminal called
  -> <IDENT, 4, B>
-> Parser rule identsep2 called
-> Parser rule analyseTerminal called
  -> <COLON, 4, :>
-> Parser rule type_n called
-> Parser rule analyseTerminal called
  -> <IDENT, 4, Integer>
-> Parser rule typexpr called
-> Parser rule analyseTerminal called
  -> <ASSIGN, 4, :=>
-> Parser rule expr called
-> Parser rule or_expr called
-> Parser rule and_expr called
-> Parser rule not_expr called
-> Parser rule equality_expr called
-> Parser rule relational_expr called
-> Parser rule additive_expr called
-> Parser rule multiplicative_expr called
-> Parser rule unary_expr called
-> Parser rule primary called
-> Parser rule analyseTerminal called
  -> <ENTIER, 4, 10>
-> Parser rule multiplicative_expr2 called
-> Parser rule additive_expr2 called
-> Parser rule relational_expr2 called
-> Parser rule equality_expr2 called
-> Parser rule not_expr2 called
-> Parser rule and_expr2 called
-> Parser rule or_expr2 called
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 4, ;>
-> Parser rule multipleDeclarations called
-> Parser rule declaration called
-> Parser rule identsep called
-> Parser rule analyseTerminal called
  -> <IDENT, 5, Sum>
-> Parser rule identsep2 called
-> Parser rule analyseTerminal called
  -> <COLON, 5, :>
-> Parser rule type_n called
-> Parser rule analyseTerminal called
  -> <IDENT, 5, Integer>
-> Parser rule typexpr called
-> Parser rule analyseTerminal called

```

```

  -> <SEMICOLON, 5, ;>
-> Parser rule multipleDeclarations called
-> Parser rule analyseTerminal called
  -> <BEGIN, 6, begin>
-> Parser rule instrs called
-> Parser rule instr called
-> Parser rule analyseTerminal called
  -> <IDENT, 7, Sum>
-> Parser rule instr2 called
-> Parser rule instr3 called
-> Parser rule analyseTerminal called
  -> <ASSIGN, 7, :=>
-> Parser rule expr called
-> Parser rule or_expr called
-> Parser rule and_expr called
-> Parser rule not_expr called
-> Parser rule equality_expr called
-> Parser rule relational_expr called
-> Parser rule additive_expr called
-> Parser rule multiplicative_expr called
-> Parser rule unary_expr called
-> Parser rule primary called
-> Parser rule analyseTerminal called
  -> <IDENT, 7, A>
-> Parser rule primary2 called
-> Parser rule acces called
-> Parser rule multiplicative_expr2 called
-> Parser rule additive_expr2 called
-> Parser rule analyseTerminal called
  -> <PLUS, 7, +>
-> Parser rule multiplicative_expr called
-> Parser rule unary_expr called
-> Parser rule primary called
-> Parser rule analyseTerminal called
  -> <IDENT, 7, B>
-> Parser rule primary2 called
-> Parser rule acces called
-> Parser rule multiplicative_expr2 called
-> Parser rule additive_expr2 called
-> Parser rule relational_expr2 called
-> Parser rule equality_expr2 called
-> Parser rule not_expr2 called
-> Parser rule and_expr2 called
-> Parser rule or_expr2 called
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 7, ;>
-> Parser rule instrs2 called
-> Parser rule analyseTerminal called
  -> <END, 8, end>
-> Parser rule hasident called
-> Parser rule analyseTerminal called
  -> <IDENT, 8, Main>
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 8, ;>
-> Parser rule analyseTerminal called
  -> <EOF, 8, >

```

FIGURE 3 – Sortie découpée de gauche à droite

Et on obtient l'arbre abstrait suivant en sortie et donc ici en json :



```

ProgramNode : {
  "rootProcedure" : ProcedureDeclarationNode : {
    "parameters" : null,
    "body" : BlockNode : {
      "statements" : [BlockNode : {
        "statements" : [],
        "declarations" : [],
      }],
      "declarations" : [TypeDeclarationNode : {
        "type" : SimpleTypeNode : {
          "typeName" : "Integer",
        },
        "name" : "A",
      }, TypeDeclarationNode : {
        "type" : SimpleTypeNode : {
          "typeName" : "Integer",
        },
        "name" : "B",
      }, TypeDeclarationNode : {
        "type" : SimpleTypeNode : {
          "typeName" : "Integer",
        },
        "name" : "Sum",
      }],
    },
  },
  "name" : "Main",
},
}

```

FIGURE 4 – Arbre abstrait

Et à l'aide de notre script python et de graphviz on obtient l'arbre abstrait suivant :




FIGURE 5 – Arbre abstrait

## 7.2 Pour un code source invalide

Voici un code source invalide en canAda qui permet de tester notre compilateur, on a volontairement rajouter un ; en trop à la fin de la ligne 5 :

```

1      with Ada.Text_IO; useAda.Text_IO;
2      procedure Main is
3          A : Integer := 5;
4          B : Integer := 10;
5          Sum : Integer;
6      begin ;
7          Sum := A + B;
8      end Main;
  
```

On obtient alors après l'analyse lexicale et syntaxique la sortie suivante, on l'a découpé en 3 parties pour plus de lisibilité et laisser sur fond noir pour faciliter la lisibilité des couleurs :

```

-> Parser rule fichier called
-> Parser rule analyseTerminal called
  -> <WITH, 1, with>
-> Parser rule analyseTerminal called
  -> <IDENT, 1, Ada>
-> Parser rule analyseTerminal called
  -> <DOT, 1, .>
-> Parser rule analyseTerminal called
  -> <IDENT, 1, Text_IO>
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 1, ;>
-> Parser rule analyseTerminal called
  -> <IDENT, 1, useAda>
-> Parser rule analyseTerminal called
  -> <DOT, 1, .>
-> Parser rule analyseTerminal called
  -> <IDENT, 1, Text_IO>
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 1, ;>
-> Parser rule analyseTerminal called
  -> <PROCEDURE, 2, procedure>
-> Parser rule analyseTerminal called
  -> <IDENT, 2, Main>
-> Parser rule analyseTerminal called
  -> <IS, 2, is>
-> Parser rule multipleDeclarations called
-> Parser rule declaration called
-> Parser rule identsep called
-> Parser rule analyseTerminal called
  -> <IDENT, 3, A>
-> Parser rule identsep2 called
-> Parser rule analyseTerminal called
  -> <COLON, 3, :=>
-> Parser rule type_n called
-> Parser rule analyseTerminal called
  -> <IDENT, 3, Integer>
-> Parser rule typexpr called
-> Parser rule analyseTerminal called
  -> <ASSIGN, 3, :=>
-> Parser rule expr called
-> Parser rule or_expr called
-> Parser rule and_expr called
-> Parser rule not_expr called
-> Parser rule equality_expr called
-> Parser rule relational_expr called
-> Parser rule additive_expr called
-> Parser rule multiplicative_expr called
-> Parser rule unary_expr called
-> Parser rule primary called
-> Parser rule analyseTerminal called
  -> <ENTIER, 4, 10>
-> Parser rule multiplicative_expr2 called
-> Parser rule additive_expr2 called
-> Parser rule relational_expr2 called
-> Parser rule equality_expr2 called
-> Parser rule not_expr2 called
-> Parser rule and_expr2 called
-> Parser rule or_expr2 called
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 4, ;>
-> Parser rule multipleDeclarations called
-> Parser rule declaration called
-> Parser rule identsep called
-> Parser rule analyseTerminal called
  -> <IDENT, 4, B>
-> Parser rule identsep2 called
-> Parser rule analyseTerminal called
  -> <COLON, 4, :=>
-> Parser rule type_n called
-> Parser rule analyseTerminal called
  -> <IDENT, 4, Integer>
-> Parser rule typexpr called
-> Parser rule analyseTerminal called
  -> <ASSIGN, 4, :=>
-> Parser rule expr called
-> Parser rule or_expr called
-> Parser rule and_expr called
-> Parser rule not_expr called
-> Parser rule equality_expr called
-> Parser rule relational_expr called
-> Parser rule additive_expr called
-> Parser rule multiplicative_expr called
-> Parser rule unary_expr called
-> Parser rule primary called
-> Parser rule analyseTerminal called
  -> <ENTIER, 4, 10>
-> Parser rule multiplicative_expr2 called
-> Parser rule additive_expr2 called
-> Parser rule relational_expr2 called
-> Parser rule equality_expr2 called
-> Parser rule not_expr2 called
-> Parser rule and_expr2 called
-> Parser rule or_expr2 called
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 4, ;>
-> Parser rule multipleDeclarations called
-> Parser rule declaration called
-> Parser rule identsep called
-> Parser rule analyseTerminal called
  -> <IDENT, 5, Sum>
-> Parser rule identsep2 called
-> Parser rule analyseTerminal called
  -> <COLON, 5, :=>
-> Parser rule type_n called
-> Parser rule analyseTerminal called
  -> <IDENT, 5, Integer>
-> Parser rule typexpr called
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 5, ;>
-> Parser rule multipleDeclarations called
-> Parser rule analyseTerminal called
  -> <BEGIN, 6, begin>
-> Parser rule instrs called
-> Parser rule analyseTerminal called
  -> <SEMICOLON, 6, ;>
-> Parser rule hasident called
-> Parser rule analyseTerminal called
  -> <IDENT, 7, Sum>
-> Parser rule analyseTerminal called
  -> <ASSIGN, 7, :=>
-> Parser rule analyseTerminal called
  -> <IDENT, 7, A>
PARSING PHASE FAILED, STOPPING

```

FIGURE 6 – Sortie découpée de gauche à droite

Et on obtient les erreurs et les warnings suivantes :

```

LISTING SYNTAX ERRORS :
Syntax error: expected <END, 6, END> but got <SEMICOLON, 6, ;> at line 6
Syntax error: expected <EOF, 7, EOF> but got <IDENT, 7, A> at line 7

```

FIGURE 7 – Erreurs

```

LISTING SYNTAX WARNINGS :
Syntax warning: missing semicolon at line 7 (got <ASSIGN, 7, :=> )

```

FIGURE 8 – Warnings

On peut ainsi voir que notre compilateur est capable de gérer les erreurs syntaxiques et de les afficher de manière claire et précise. Ainsi que de nous aider à le corriger notamment à travers les warnings et le

*Panic Mode* qui permet de continuer à analyser le programme source jusqu'à la fin tout en indiquant les erreurs rencontrées.

Ce qui conclue la partie sur les tests et la validation de notre compilateur. Bien évidemment, de nombreux autres tests ont été réalisés pour valider notre compilateur notamment des tests unitaires pour tester le *Lexer* et le *Parser* ainsi que la construction l'arbre abstrait.

## 8 Gestion de projet

### 8.1 Équipe de projet

Ce projet est un projet local réalisé en groupe de 3 personnes :

- Alexis MARCEL
- Lucas LAURENT
- Noé STEINER

### 8.2 Organisation au sein de l'équipe projet

Nous avons réalisé plusieurs réunions, en présentiel dans les locaux de Télécom Nancy mais la plupart de notre collaboration a eu lieu sur Discord. Ces réunions nous ont permis de mettre en commun nos avancées régulièrement, de partager nos connaissances sur des problématiques et de nous organiser de manière optimale. En plus des réunions d'avancement régulières, nous avons également réalisé des réunions techniques afin de résoudre un problème ou bien de réfléchir à la conception.

Ensuite, nous avons utilisé GitLab pour gérer les différentes versions du développement de notre application, ainsi que les différentes branches nous permettant de travailler simultanément sans conflit.

### 8.3 Matrice RACI

Nous avons choisi de ne pas faire de matrice RACI à cause des choix d'organisation que nous avons faits. En effet, nous avons décidé de travailler en groupe sur toutes les tâches, ce qui fait que nous sommes tous responsables de toutes les tâches et qu'il n'y a, de ce fait, pas de répartition précise des tâches.

<b>Matrice RACI (R = Réalise ; A = Autorité ; C = Consulté ; I = Informé)</b>	<b>Acteurs</b>		
<b>Tâches</b>	Lucas	Noé	Alexis
<b>Grammaire</b>			
Réalisation d'une grammaire LL(1)	R	I	I
<b>Analyseur Lexical</b>			
Réalisation de la structure du Lexer	I	R	R
Implémentation des Token et des Tag	R	R	R
Gestion de la lecture d'un fichier Token par Token	I	R	R
<b>Analyseur Syntaxique</b>			
Réalisation de la structure du Parser	R	C	I
Gestion des erreurs	R	R	I
Implémentation des règles	R	R	R
<b>Arbre Abstrait</b>			
Réalisation de la structure de l'arbre abstrait	I	R	I
Implémentation des différentes nodes	I	R	R
<b>Rédaction du rapport</b>	R	C	C

FIGURE 9 – Matrice RACI

## 8.4 Répartition du Temps de Travail sur le Projet

On peut voir que la répartition du temps de travail est équilibrée entre les membres de l'équipe, ce qui a permis une contribution égale de tous les membres de l'équipe :

Tâche	Lucas	Noé	Alexis
Grammaire	10h	-	-
Structure du Lexer	-	2h	4h
Lecture du fichier (token par token)	-	5h	7h
Implémentation des Token et des Tag	2h	2h	2h
Structure du Parser	1h	-	-
Gestion des erreurs	4h	4h	-
Implémentation des règles	3h	3h	3h
Structure de l'arbre abstrait	-	2h	-
Implémentation des différents nodes	-	6h	6h
Rédaction du rapport	4h	-	-
Total	24h	24h	22h

## 9 Conclusion

Ce rapport a présenté en détail le processus de développement d'un compilateur pour le langage *canAda*, réalisé dans le cadre du module PCL1 à TELECOM Nancy. Le projet a débuté par la transfor-

mation de la grammaire originale en une grammaire LL(1), adaptée pour une analyse syntaxique précise. Cette transformation a impliqué l'élimination de la récursivité à gauche, la factorisation, et la gestion des priorités de calculs pour assurer une analyse déterministe.

L'analyse lexicale a été effectuée par le *Lexer*, un composant clé qui convertit le code source en tokens, en s'appuyant sur un ensemble de règles prédéfinies et un système efficace de lecture en avance et d'une astuce pour déterminer la fin d'un token ce qui nous a permis de nous passer d'un automate à états finis. La classe *Parser*, quant à elle, a joué un rôle essentiel dans l'analyse syntaxique, en décomposant le programme source en ses composants syntaxiques, tout en gérant les erreurs syntaxiques de manière robuste.

La construction de l'arbre abstrait syntaxique (AST) a été une étape cruciale, permettant une représentation concise et manipulable du programme source pour les étapes ultérieures de la compilation. Chaque nœud de l'AST, tel que *OperatorNode* ou *ProgramNode*, a capturé des éléments essentiels des structures syntaxiques du langage *canAda*.

La répartition du temps de travail sur les différentes tâches a été équilibrée, assurant ainsi une contribution égale de tous les membres de l'équipe.

En conclusion, ce projet a non seulement abouti à la création d'un compilateur fonctionnel pour *canAda* mais a également permis aux membres de l'équipe d'approfondir leurs compétences en informatique, notamment dans les domaines de l'analyse lexicale et syntaxique, ainsi que dans la construction et la manipulation d'arbres abstraits. Ce projet représente une étape significative dans notre parcours d'ingénieurs en informatique, nous préparant efficacement à des applications concrètes dans divers secteurs technologiques.

Il a également renforcé notre compréhension des fondamentaux de la compilation, une compétence essentielle pour tout développeur de logiciels ainsi que pour tout ingénieur en informatique.